


Geodatenanalyse I: Räumliche Interpolation

Kathrin Menberg



Stundenplan

Vorläufiger Stundenplan		
Datum	Thema	Dozent
20.10.2021	Einführung in die Programmierung mit <i>Python</i>	Gabriel Rau
25.10.2021	Univariate Statistik und statistisches Testen	Kathrin Menberg
01.11.2021	<i>Feiertag</i>	
08.11.2021	Umgang und Berechnung von Datensätzen	Gabriel Rau
15.11.2021	Bivariate und schließende Statistik	Kathrin Menberg
22.11.2021	Datenvisualisierung mit <i>matplotlib</i>	Gabriel Rau
29.11.2021	Multivariate Statistik	Kathrin Menberg
06.12.2021	Datenformate, Datenspeicherung und Datenbanken	Gabriel Rau
13.12.2021	Monte-Carlo Methoden	Kathrin Menberg
20.12.2021	Analyse und Visualisierung von Geodaten	Gabriel Rau
27.12.2021	<i>Weihnachtsferien</i>	
03.01.2022	<i>Weihnachtsferien</i>	
10.01.2022	Sensitivitätsanalyse	Kathrin Menberg
17.01.2022	Datenethik, Lizenzierung und Entwicklungstools	Gabriel Rau
24.01.2022	Räumliche Interpolation	Kathrin Menberg
31.01.2022	Fragen zur Programmierung	Gabriel Rau
07.02.2022	Regressionsanalyse	Kathrin Menberg

Vorlesungsplan

Uhrzeit	Inhalt
10:00 – 10:20	Deterministische Interpolation
10:20 – 11:00	Übung
11:00 – 11:10	Diskussion und Reflexion
11:10 – 11:25	<u>Pause</u>
11:25 – 11:45	Kriging
11:45 – 12:20	Übung
12:20 – 12:30	Diskussion und Reflexion

Lernziele

Am Ende der Stunde werden die Teilnehmer:



- ▶ ... mit den mathematischen Grundlagen der Interpolation vertraut sein.
- ▶ ... verschiedene Methoden zur Interpolation voneinander abgrenzen können.
- ▶ ... in Python deterministische Methoden zur Interpolation von Datensätzen anwenden und die Ergebnisse graphisch darstellen können.

Interpolation


- Motivation
 - $X_i \rightarrow f(x)$
 - räumliche Interpolation

Punkte (Linien)


Isolinien, Rasterdaten



1D, 2D, n-dimensionale Interpolation




<https://datascience.stackexchange.com/>




<https://rbf.readthedocs.io/>

<https://innolitics.com/>




Interpolation vs. Extrapolation

- ▶ Interpolation: Schätzung von Werten zwischen bekannten Datenpunkten
- ▶ Extrapolation: Schätzung von Werten außerhalb bekannter Datenpunkte



Interpolation



Extrapolation




<https://www.informatik.uni-augsburg.de/>

Deterministische Interpolation

- ▶ Interpolation mittels festgelegter (z.B. linearer) Funktion
- ▶ Eindeutiges, immer gleiches Ergebnis
- ▶ Einfache Berechnung, aber keine Aussage zur Qualität der Interpolation möglich
- ▶ Beispiele:
 - ▶ Triangulation
 - ▶ Nearest Neighbour
 - ▶ Natural Neighbour
 - ▶ Spline Interpolation
 - ▶ Polynomische Interpolation
 - ▶ Inverse Distance Weighting
 - ▶ usw.

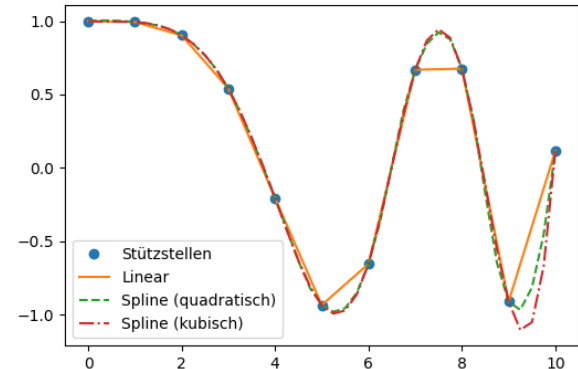
Nearest Neighbour

- Verbindung jeweils dreier benachbarter Punkte mittels Delaunay-Triangulation
- Mittelsenkrechten der Dreiecksmaschen ergeben sog. Thiessen-Polygone oder auch Voronoi-Polygone
- Zuordnung des jeweils nächstgelegenen Messwertes („nearest neighbour“) für das ganze Polygon



Radiale Basisfunktionen (RBF)

- ▶ Reelle Funktion φ , deren Wert nur vom Abstand zum Ursprung abhängt
- ▶ Abstand: Euklidische Distanz
- ▶ Verschiedene Funktionstypen:
 - ▶ Linear
 - ▶ Spline $\varphi(r) = r^k$, $\varphi(r) = r^k \ln(r)$
 - ▶ Multi-quadratisch $\varphi(r) = \sqrt{1 + (ar)^2}$
 - ▶ Gauss $\varphi(r) = e^{-(ar)^2}$
 - ▶ ...
- ▶ Annahme Formparameter a , bzw. k
- ▶ Approximation von Werten zwischen Stützpunkten
 - ▶ Interpolation
 - ▶ Maschinelles Lernen (z.B. Neuronale Netze)



Inverse Distance Weighting

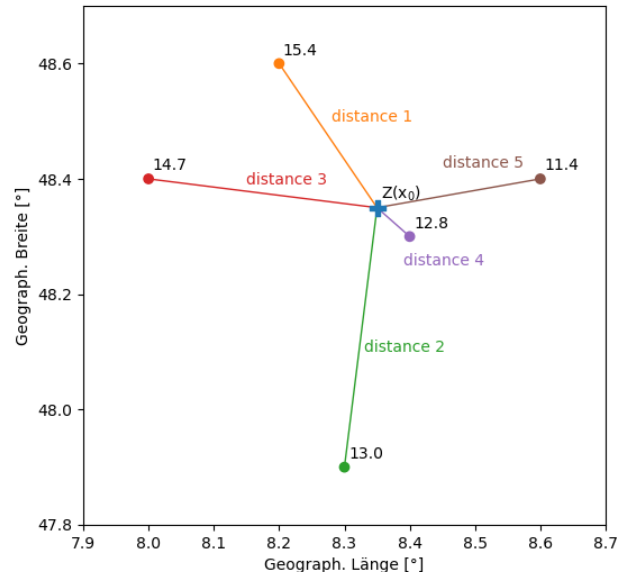
- Interpolationswert \hat{Z} an Stelle x_0 wird berechnet aus den Messwerten $Z(x_i)$ der benachbarten Punkte $x_1 \dots x_i$

$$\hat{Z}(x_0) = \sum_{i=1}^n \lambda_i \cdot Z(x_i)$$

- λ_i ist die Gewichtung, mit dem der Wert x_i an Punkt i in die Berechnung einfließt


$$\lambda_i = \frac{d_{i0}^{-p}}{\sum_{i=1}^n d_{i0}^{-p}}$$

- Mit zunehmender Entfernung d nimmt das Gewicht ab.



Inverse Distance Weighting


- ▶ p „Power“ ist ein Maß für Abnahme (i.d.R. >1 , z.B. 2)
- ▶ Einfluss des Wertes p
- ▶ Welches der optimale p -Wert ist, kann man über Validierungsverfahren feststellen.



Inverse Distance Weighting

- Anzahl der bei der Interpolation berücksichtigten Punkte

fixed distance



distance (radius)

fixed number



number of points
(nearest 6)

+ interpolation point

• data point found

◦ data point ignored

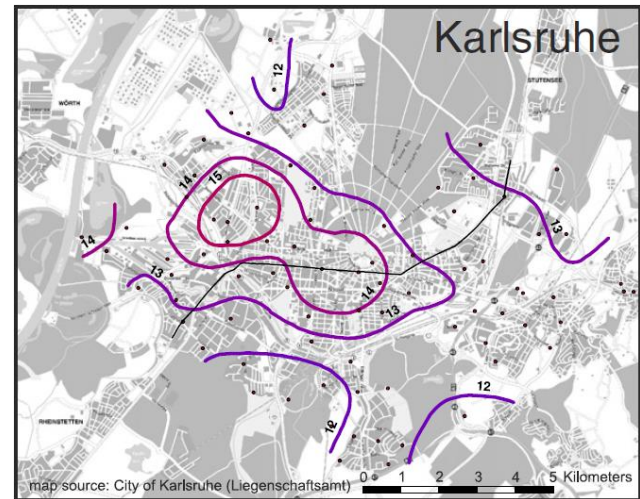
- Welche Methode man wählt, hängt sehr stark von der Verteilung der Messpunkte ab
- Bei homogener Verteilung liefern beide Methoden das gleiche Ergebnis

Übung 9: Interpolation 1

► Interpolation von Grundwasserdaten in Karlsruhe

- Delauney Triangulation
- Nearest Neighbour
- Radiale Basisfunktionen
- Visualisierung

► Aufgaben in Jupyter Notebook: 09_Räumliche Interpolation_1



Menberg et al. (2013)

Pause

... bis 11:25 Uhr



Vorlesungsplan

Uhrzeit	Inhalt
10:00 – 10:20	Deterministische Interpolation
10:20 – 11:00	Übung
11:00 – 11:10	Diskussion und Reflexion
11:10 – 11:25	<u>Pause</u>
11:25 – 11:45	Kriging
11:45 – 12:20	Übung
12:20 – 12:30	Diskussion und Reflexion

Lernziele

Am Ende der Stunde werden die Teilnehmer:

- ▶ ... mit den mathematischen Grundlagen der Semivariogramm Analyse vertraut sein.
- ▶ ... verschiedenen Typen von Variogrammen kennen und diese auf Datensätze anpassen können.
- ▶ ... in Python Kriging für Datensätze mit und ohne Trend durchführen können.

Stochastische Interpolation

- ▶ Geostatistische Verfahren
- ▶ Ergebnis ist eine von vielen möglichen Realisationen
- ▶ Interpolation basierend auf den statistischen Eigenschaften der Daten
- ▶ Statistische Auswertung der Wahrscheinlichkeit und Unsicherheit der Interpolationsergebnisse
- ▶ Möglichkeit der Qualitätsbestimmung der Interpolation
- ▶ z.B. Kriging

Kriging

- ▶ Motivation: Bestimmung der Wahrscheinlichkeit an einem Ort Gold zu finden, basierend auf Proben von ein paar wenigen Bohrlöchern
- ▶ Verfahren basierend auf Inverse Distance Weighting...
- ▶ ... unter Berücksichtigung der **räumlichen Varianz** der Daten
- ▶ Kriging gliedert sich in zwei Schritte:
 - ▶ Analyse der räumlichen Korrelation, bzw. Varianz der Daten
 - ▶ eigentliche Kriging-Interpolation


Kriging Grundgleichung

$$\hat{Z}(x_0) = \sum_{i=1}^n \lambda_i \cdot Z(x_i), \quad \text{mit} \quad \sum_{i=1}^n \lambda_i = 1$$

- ▶ $\hat{Z}(x_0)$ = Schätzwert am Punkt x_0
- ▶ n = Anzahl Datenwerte, die zur Schätzung herangezogen werden
- ▶ $Z(x_i)$ = Messwert am Punkt x_i
- ▶ λ_i = Gewichte, mit der der jeweilige Datenwert bei der Interpolation gewichtet wird
- ▶ Unterschiede zu IDW:
 - ▶ Berechnung der Gewichte
 - ▶ Annahme dass $\hat{Z}(x_0)$ eine Zufallsgröße ist

Kriging Gewichtung

- ▶ Berücksichtigung von Heterogenität der Messpunkte
 - ▶ Gewichte von Punkten innerhalb von Clustern werden gesenkt
- ▶ Bestimmung der Gewichte so, dass Varianz des Schätzfehlers möglichst gering ist
- ▶ Ermittlung der Gewichte mittels (Semi-) Variogrammanalyse



Variogrammanalyse

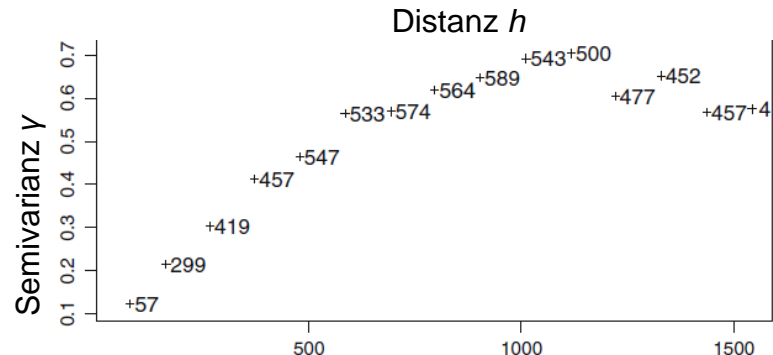
- Semivarianz $\gamma(h)$: Maß für den Grad der räumlichen Abhängigkeit von Messwerten

$$\gamma(h) = \frac{1}{2n} \sum_{i=1}^n (Z(x_i) - Z(x_i + h))^2$$

- n = Anzahl Datenwerte, die zur Schätzung herangezogen werden
- $Z(x_i)$ = Messwert am Punkt x_i
- $Z(x_i + h)$ = Messwert an einem Punkt im Abstand h


Bivand et al. (2008)

- halbe, mittlere, quadrierte euklidische Distanz zwischen zwei Messwerten




Experimentelles Variogramm

- ▶ Auftragen der (Semi-)Varianz $\gamma(h)$ über dem Abstand h
- ▶ Experimentelles Variogramm \rightarrow Messwerte




Schwellenwert und Reichweite

- ▶ Schwellenwert (Sill): verglichene Werte haben keinen Bezug mehr zueinander, ihre quadrierten Differenzen entsprechen der Varianz um den Mittelwert
- ▶ Reichweite (Range) = Abstand, unterhalb dem die Werte als räumlich in Beziehung stehend gelten können, darüber keine räumliche Korrelation mehr



Nugget-Effekt


- ▶ Nugget (y-Achsen-Abstand): charakterisiert Variablen, deren Variabilität kleinräumiger als die geringsten Probenabstände ist.
- ▶ kann aber auch durch Fehler im Datensatz, z.B. durch aufgrund der Probenahme oder der Analyse, verursacht werden.




Theoretisches Variogramm

- Anpassung des experimentellen Variogramms mit einer Funktion
- z.B. sphärische Funktion, lineare Funktion, usw.


Lineares Variogramm



Exponentielles Variogramm



Gauß-Variogramm



Bivand et al. (2008)

Ordinary Kriging

- ▶ Es liegt kein Trend (und keine Drift) in den Daten vor, d.h. die Differenz zwischen Schätzung und den wahren Werten soll im Mittel gleich 0 sein
- ▶ Die Varianz (Kriging-/Schätzvarianz) des Schätzfehlers soll minimal sein.
- ▶ Die Summe aller Gewichte muss 1 ergeben

$$\hat{\sigma}^2 = \sum_{i=1}^n \lambda_i \cdot \gamma_{i0} + \mu \rightarrow \min.$$

und
$$\sum_{i=1}^n \lambda_i = 1$$

$\hat{\sigma}^2$ = Varianz

λ_i = Gewicht für Messpunkt i

γ_{i0} = Semivarianz für Messpunkt i und Punkt 0


μ = Lagrange-Faktor

$$Z(s) = \mu(s) + \varepsilon(s)$$

$Z(s)$: Vorhersagewert (an Lokalität s)

$\mu(s)$: deterministischer Trend (Erwartungswert)

$\varepsilon(s)$: autokorrelierte Zufallsfehler



Universal Kriging


- Finden Anwendung, wenn Daten mit einem Trend (oder Drift) behaftet sind
- Trend: über das gesamte Gebiet (globaler Trend)
- Drift: nur lokal (lokale Drift)

$$Z(s) = \mu(s) + \varepsilon(s)$$

mit: $Z(s)$: Vorhersagewert (an Lokalität s)

$\mu(s)$: deterministischer Trend (Erwartungswert)


$\varepsilon(s)$: autokorrelierte Zufallsfehler



Root Mean Square Error (RMSE)

- ▶ dt. Wurzel der mittleren Fehlerquadratsumme
- ▶ y : Beobachtungen, \hat{y}_i Vorhersagen

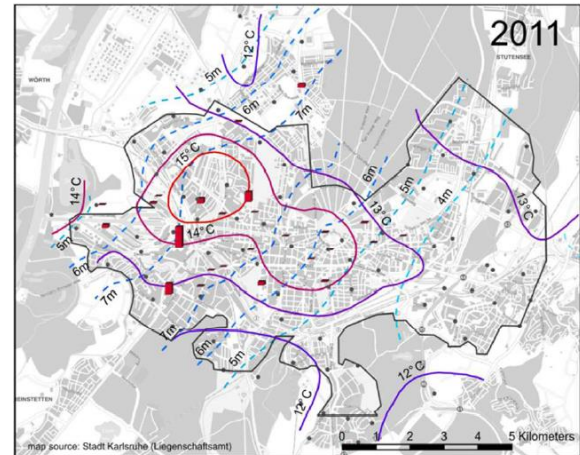
$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$




- ▶ Maß für die Güte der Anpassung, bzw. Genauigkeit der Vorhersagen
- ▶ Perfekte Anpassung, bzw. Übereinstimmung $RMSE = 0$
- ▶ Je größer, desto schlechter ist die Anpassung
- ▶ Magnitude abhängig vom Maßstab der Datenwerte
- ▶ Relatives Fehlermaß!

Übung 10: Interpolation 2

- ▶ Kriging mit Grundwasserdaten aus Karlsruhe
- ▶ Ordinary Kriging der Grundwassertemperaturen
- ▶ Universal Kriging der Grundwasserstände
- ▶ Analyse der Vorhersagegenauigkeit
- ▶ Aufgaben in Jupyter Notebook: 10_Räumliche Interpolation_2



groundwater temperature



water level below the surface



Menberg et al. (2013)

Literatur

- ▶ Bivand, Pebesma & Gomez-Rubio (2008): Applied Spatial Data Analysis with R, Springer
- ▶ Oliver & Webster (2015): Basic Steps in Geostatistics: The Variogram and Kriging, Springer
- ▶ Menberg et al. (2013): Subsurface urban heat islands in German cities, Sci. Tot. Environ. 442 (2013) 123-133.
- ▶ Menberg et al. (2013): Long-term evolution of anthropogenic heat fluxes into a subsurface urban heat island, Environ. Sci. Technol. 47(17) (2013) 9747-9755

Nützliche Weblinks:

- ▶ <https://towardsdatascience.com/what-does-rmse-really-mean-806b65f2e48e>

